
УНИВЕРЗИТЕТ „СВ. КИРИЛ И МЕТОДИЈ“

Факултет за информатички науки и компјутерско инженерство

Предмет: Веб базирани системи

ПРОЕКТНА ДОКУМЕНТАЦИЈА

**Развој на граф на знаење за македонската историја,
негово поврзување со интернационалните историски бази на податоци
и моделирање како временски граф на знаење**

1. Апстракт	4
2. Вовед	5
2.1. Опис на проблемот	5
2.2. Очекувани придобивки	5
3. Теоретска основа	6
3.1. Графови на знаење	6
3.2. Временски графови на знаење	6
3.3. Поврзување со надворешни историски извори	6
4. Анализа на системот	8
4.1. Главни функционалности	8
4.2. Кориснички сценарија	8
4.3. Архитектура на решението	9
5. Користени технологии	10
5.1. Backend	10
5.2. Frontend	10
5.3. База на податоци	10
6. Имплементација	11
6.1. Структура на проектот	11
7. Модел на податоци	12
7.1. Типови на јазли (класи)	12
7.2. Типови на врски	12
7.3. Временски атрибути	13
7.4. Организација на графот	13
8. Кориснички интерфејс	14
8.1. Почетна страница (/)	14
8.2. Страница за пребарување (/search)	14
8.3. Временска линија (/timeline)	14
8.4. Граф explorer (/graph)	14
8.5. Карта (/map)	15
8.6. Детален запис за ентитет (/entity/{uri})	15
8.7. SPARQL editor (/queries)	15
8.8. Извештај (/report)	15
9. Интеграција со интернационални историски бази на податоци	16
9.1. Wikidata — примарен извор	16
9.2. Надворешни авторитативни бази	16
9.3. Размена на податоци	17
10. Предности и ограничувања на системот	18

10.1. Предности.....	18
10.2. Ограничувања	18
11. Можни идни подобрувања.....	19
12. Заклучок	20

1. Апстракт

Овој проект претставува имплементација на граф на знаење за македонската историја, развиен во рамките на предметот Веб базирани системи. Системот собира структурирани историски податоци од Wikidata преку SPARQL прашалници, ги обработува и претвора во RDF формат, по што ги складира во Apache Jena Fuseki, семантичка база на податоци која овозможува пристап и пребарување преку SPARQL endpoint. Пристапот до податоците е овозможен преку веб-апликација изградена со FastAPI и Jinja2, која нуди интерактивна граф визуелизација со D3.js, временска линија, географска карта базирана на Leaflet и SPARQL едитор за пребарување и анализа на податоците.

Историскиот опсег ги опфаќа настаните и личностите поврзани со македонскиот национален препород и ослободителните движења во периодот 1885–1910 година, со акцент на Илинденското востание (1903) и Крушевската Република. Графот на знаење содржи шест категории на ентитети: историски личности, настани, места, организации, документи и периоди, поврзани преку дефиниран онтолошки речник со просторни и временски атрибути. Секој ентитет е поврзан со соодветниот запис во Wikidata преку owl:sameAs врска, а исто така содржи линкови кон VIAF, ISNI, Library of Congress, GND, BnF, IdRef и GeoNames.

2. Вовед

2.1. Опис на проблемот

Историските информации за македонскиот национален препород се расфрлани низ различни дигитални извори како Wikidata, Wikipedia, национални библиотеки и архиви. Голем дел од тие информации не се меѓусебно поврзани, па е тешко да се постави прашање: кои личности учествувале во исто востание, или кои организации биле основани во истото место за истиот период.

Традиционалните релациони бази на податоци имаат ограничувања при обработката на сложени прашалници кои вклучуваат повеќекратни релации и поврзани ентитети во графовска структура. Семантичките технологии (RDF, SPARQL) нудат флексибилен модел во кој секој факт е тројка (субјект, предикат, објект), а прашањата можат да пребаруваат произволно длабоки врски.

2.2. Очекувани придобивки

- Структурирано и машински читливо знаење за македонската историја.
- Семантичко поврзување на локалните историски записи со меѓународни авторитативни бази (VIAF, GND, Library of Congress и др.).
- Временска димензија на графот — поддршка за прашања базирани на временски интервали (OWL-Time онтологија).
- Интерактивна визуелизација на сложени историски врски преку граф, временска линија и карта.

3. Теоретска основа

3.1. Графови на знаење

Граф на знаење (Knowledge Graph) е структура на податоци во која ентитетите се претставени со јазли, а врските меѓу нив со ребра. Формално, тоа е граф каде секоја тројка (субјект, предикат, објект) изразува еден факт. Оваа репрезентација е стандардизирана преку RDF (Resource Description Framework), W3C препорака за размена на структурирани податоци на вебот.

Во контекст на проектот, јазлите претставуваат историски ентитети (личности, настани, места, организации, документи и периоди) идентификувани со URI. Ребрата претставуваат семантички релации дефинирани во рамките на custom онтологија со namespace mko: (<http://macedonian-history.mk/ontology#>). Оваа онтологија користи стандардни вокабулари: RDFS за означување и хиерархија на класи, OWL за еквиваленција (`owl:sameAs`) и Schema.org за описи.

3.2. Временски графови на знаење

Временски граф на знаење ги надградува стандардните графови со додавање на временска димензија на фактите. Во овој проект тоа е реализирано на два начина: преку директни атрибути на ентитетите (`mko:startDate`, `mko:endDate`, `mko:birthDate`, `mko:deathDate` и сл.) и преку OWL-Time онтологијата (<http://www.w3.org/2006/time#>) за именувани временски интервали.

Скриптата `temporal_modeling.py` (`scripts/4. temporal_modeling.py`) генерира именувани графови во NQuads и TriG формат, каде секој историски факт е сместен во временски контекст. Ова овозможува прашања базирани на Allen-овата алгебра на временски интервали, поддржана преку SPARQL датотеката `queries/13_allen_during.rq`.

3.3. Поврзување со надворешни историски извори

Концептот Linked Open Data (LOD) предвидува дека ентитетите во различни бази на податоци треба да се поврзуваат преку `owl:sameAs` врски. Во овој проект секој ентитет собран од Wikidata е поврзан со неговиот Wikidata URI, а доколку во Wikidata постојат идентификатори за надворешни бази, тие се исто така зачувани во графот преку `mko:externalLink` и `rdfs:seeAlso` предикати.

Поддржаните надворешни идентификатори (по Wikidata property) се: P214 (VIAF), P213 (ISNI), P244 (Library of Congress), P227 (GND — Германска национална библиотека), P268 (BnF — Француска национална библиотека), P269 (IdRef — француски референтен систем), P1566 (GeoNames) и DBpedia.

4. Анализа на системот

4.1. Главни функционалности

Системот се состои од два главни слоја: pipeline за подготовка на податоци (скрипти) и веб апликација за пребарување и визуелизација.

- **Собирање податоци:** Скриптата `scrape.py` собира RDF тројки од Wikidata SPARQL endpoint, почнувајќи од seed ентитети (Илинденско востание, Крушевска Република, Македонија) и проширувајќи се преку поврзаните личности, места и организации.
- **Валидација и чистење:** Скриптата `validate_clean.py` ги валидира класите на ентитети, форматите на датуми, јазичните ознаки и ги отстранува невалидни URI-а и други грешки.
- **Временско моделирање:** Скриптата `temporal_modeling.py` генерира именувани временски контексти во NQuads/TriG формат.
- **Пребарување:** Real-time пребарување по назив на ентитет преку HTMX со debounce 350ms.
- **Временска линија:** Хронолошки приказ на настани со можност за филтрирање по датумски опсег.
- **Граф explorer:** Интерактивен force-directed граф со контроли за длабочина (1–3 нивоа), лимит (150–900 јазли), филтри по тип на ентитет и анимација по години.
- **Географска карта:** Карта со маркери за историски места и рорир прикази на поврзани настани.
- **Детали за ентитет:** Страница со сите атрибути на избран ентитет, влезни и излезни релации и суровите RDF тројки.
- **SPARQL editor:** Интерфејс за извршување на прилагодени SPARQL прашалници со 14 вградени примери.
- **Извештај:** Автоматски генериран Markdown извештај за квалитетот на графот (број на ентитети, недостасувачки ознаки, потенцијални грешки).

4.2. Кориснички сценарија

- **Сценарио 1 — Истражување на личност:** Корисникот го пребарува Гоце Делчев. Системот враќа листа на резултати со тип и датум. Корисникот кликнува и гледа детален запис: датуми на раѓање и смрт, место на раѓање, членство во ТМОРО, настани во кои учествувал, и надворешни линкови кон VIAF и Library of Congress.
- **Сценарио 2 — Временска линија:** Корисникот ја отвора временската линија и поставува филтер 1895–1905. Системот прикажува хронолошки листа на настани, вклучувајќи го Илинденското востание (1903) со место и датум.
- **Сценарио 3 — Граф explorer:** Корисникот го одбира Илинденското востание како центар, поставува длабочина 2 и гледа цел граф на поврзани личности, места и организации. Ја активира анимацијата по години и гледа кои ентитети постоеле во 1903.

- **Сценарио 4 — Географска карта:** Корисникот ја отвора картата и гледа маркери за Крушево, Битола и Солун. Кликнувањето на маркерот за Крушево прикажува листа на настани поврзани со тоа место.
- **Сценарио 5 — SPARQL прашалник:** Напреден корисник ја избира датотеката 04_people_alive_during_ilinden.rq и ги гледа сите личности кои биле живи за време на Илинденското востание.

4.3. Архитектура на решението

Системот следи трослојна архитектура: слој за собирање/подготовка на податоци, слој за складирање и прашања, и презентациски слој.

Слој	Компонента	Технологија
Собирање податоци	Web scraper / RDF builder	Python, Requests, RDFLib
Валидација	Graph cleaner	Python, RDFLib
Временско моделирање	Temporal graph builder	Python, RDFLib, OWL-Time
Складирање	Триплет продавница	Apache Jena Fuseki
Прашалници	SPARQL endpoint	Apache Jena Fuseki (порт 3030)
Backend	REST API	FastAPI, Jinja2
Frontend	Динамичен UI	HTMX, Tailwind CSS
Граф визуел.	Force-directed граф	D3.js v7
Карта	Интерактивна карта	Leaflet 1.9.4

Комуникацијата помеѓу FastAPI апликацијата и RDF базата се реализира преку HTTP протокол, при што SPARQL прашалниците се испраќаат до SPARQL endpoint обезбеден од Apache Jena Fuseki. Фронтендот комуницира со бекендот преку стандардни HTTP GET/POST барања.

5. Користени технологии

5.1. Backend

- **FastAPI**
- **Jinja2**

5.2. Frontend

- **HTMX**
- **Tailwind CSS**
- **D3.js**
- **Leaflet**

5.3. База на податоци

- **Apache Jena Fuseki**

6. Имплементација

6.1. Структура на проектот

Проектот е организиран во следната директориумска структура:

Патека	Опис
scraping/app/main.py	FastAPI апликација — рути, SPARQL логика
scraping/app/sparql_client.py	SPARQL клиент за Fuseki со error handling
scraping/app/queries.py	Предефинирани SPARQL прашалници (HOME_STATS, SEARCH, TIMELINE и др.)
scraping/app/templates/	Jinja2 HTML темплејти
scraping/scripts/1. scrape.py	Собирање на податоци од Wikidata
scraping/scripts/2. validate_clean.py	Валидација и чистење на RDF граф
scraping/scripts/3. graph_report.py	Генерирање на Markdown извештај
scraping/scripts/4. temporal_modeling.py	Генерирање на временски именувани графови
scraping/output/	Генерирани RDF датотеки (.ttl, .nq, .trig, .md)
scraping/queries/	SPARQL датотеки со примери (.rq)

7. Модел на податоци

7.1. Типови на јазли (класи)

Сите ентитети во графот припаѓаат на една од следните шест класи, дефинирани во mko: namespace:

Класа	URI	Опис
HistoricalPerson	mko:HistoricalPerson	Историска личност со биографски атрибути
HistoricalEvent	mko:HistoricalEvent	Историски настан со временски и просторни атрибути
HistoricalPlace	mko:HistoricalPlace	Географска локација со координати
Organization	mko:Organization	Историска организација, политичка партија или движење
HistoricalDocument	mko:HistoricalDocument	Историски документ или публикација
Period	mko:Period	Историски период со почеток и крај

7.2. Типови на врски

Предикат	Домен	Опсег	Значење
mko:participatedIn	Person/Org	Event	Учество во настан
mko:tookPlaceIn	Event	Place	Локација на настан
mko:memberOf	Person/Org	Organization	Членство во организација
mko:ledBy	Org/Event	Person	Раководство
mko:bornIn	Person	Place	Место на раѓање
mko:locatedInCountry	Place	Place	Место на престој
mko:authoredBy	Document	Person	Авторство на документ
mko:headquarteredIn	Organization	Place	Седиште на организација
mko:partOf	Entity	Period/Org	Дел-целина релација
owl:sameAs	Entity	Wikidata URI	Еквиваленција со Wikidata запис
mko:externalLink	Entity	External URI	Врска до надворешна база
rdfs:seeAlso	Entity	External URI	Дополнителна референца

7.3. Временски атрибути

Атрибут	Применливост	Формат	Опис
mko:birthDate	HistoricalPerson	xsd:gYear	Година на раѓање
mko:deathDate	HistoricalPerson	xsd:gYear	Година на смрт
mko:startDate	Event/Period	xsd:gYear	Почеток на настан/период
mko:endDate	Event/Period	xsd:gYear	Крај на настан/период
mko:foundingDate	Organization	xsd:gYear	Датум на основање
mko:dissolutionDate	Organization	xsd:gYear	Датум на распуштање
mko:dateCreated	Document	xsd:gYear	Датум на создавање
time:hasBeginning	Интервал	time:Instant	OWL-Time: почеток на интервал
time:hasEnd	Интервал	time:Instant	OWL-Time: крај на интервал
time:inXSDDate	time:Instant	xsd:date	Конкретен датум на момент
mko:dateConfidence	Сите	xsd:string	Индикатор за неизвесност на датум

7.4. Организација на графот

Основниот граф (mk_history_clean.ttl) е единечен RDF граф без именување. При временското моделирање, скриптата `temporal_modeling.py` генерира Named Graphs каде секој временски контекст добива свој URI. Ова овозможува извршување на SPARQL прашалници со GRAPH клаузула, со што фактите можат да се пребаруваат и анализираат во рамките на конкретен временски контекст.

Namespace структурата е организирана на следниов начин:

- **mko:** `http://macedonian-history.mk/ontology#` - доменска онтологија која ги дефинира класите, својствата и релациите во графот на знаење.
- **mkr:** `http://macedonian-history.mk/resource/` - простор на имиња за ресурсите, односно ентитетите (инстанците) во графот.
- **oldmko:** / **oldmkr** - легаси namespace-и зачувани заради компатибилност со претходните верзии на моделот и податоците.
- **owl:**, **rdf:**, **rdfs:**, **schema:**, **time:**, **geo:**, **dcterms** - стандардни RDF и W3C вокабулари кои се користат за дефинирање на семантиката, временските и просторните атрибути, како и метаподатоците на ентитетите.

8. Кориснички интерфејс

8.1. Почетна страница (/)

Почетната страница претставува централна влезна точка во системот. Таа содржи воведна секција со краток опис на проектот и статистички картички кои прикажуваат агрегирани информации за графот, вклучувајќи го вкупниот број на ентитети, настани и места, бројот на поврзувања со Wikidata и временски опсег на податоците.

8.2. Страница за пребарување (/search)

Страницата за пребарување овозможува пронаоѓање на ентитети преку текстуален внес. По секоја промена во полето за пребарување, се испраќа асинхрон барање со помош на HTMX, а резултатите се ажурираат без повторно вчитување на страницата. За секој пронајден запис се прикажуваат називот, типот на ентитетот и релевантните датуми. Изборот на резултат отвара детален приказ на ентитетот.

8.3. Временска линија (/timeline)

Временската линија обезбедува хронолошки приказ на историските настани. Корисникот може да постави почетен и краен датум за филтрирање на резултатите. Настаните се подредени според нивниот датум на започнување, при што секој запис содржи датум, назив и поврзано место.

8.4. Граф explorer (/graph)

Граф истражувачот претставува најкомплексната компонента на системот и овозможува интерактивна визуелизација на графот на знаење. Корисникот може да ја контролира длабочината на пребарување, максималниот број на прикажани јазли и типовите на ентитети кои ќе бидат вклучени во визуелизацијата. Поддржани се и временски филтри, како и анимација која го прикажува развојот на графот низ времето.

Визуелизацијата е реализирана со D3.js како force-directed граф, со поддршка за зумирање, поместување на јазлите и интерактивен избор на елементи. Јазлите се обоени според нивниот тип, а страничниот панел прикажува детални информации за избраниот ентитет или релација.

8.5. Карта (/map)

Страницата со карта прикажува интерактивна географска визуелизација базирана на Leaflet. На картата се прикажуваат сите историски места за кои се достапни координати. Корисникот може да пребарува места преку страничен панел или да избере маркер директно од картата. При избор на маркер се отвара информативен прозорец со називот на местото и поврзаните историски настани. Легендата ги разликува различните категории локации, како што се градови

8.6. Детален запис за ентитет (/entity/{uri})

Оваа страница прикажува детален профил на избраниот елемент. Покрај основните атрибути и временски податоци, се прикажуваат врски кон Wikidata и други авторитетни извори. Страницата овозможува преглед на влезните и излезните релации, со што корисникот може да ја анализира позицијата на ентитетот во графот на знаење. Дополнително, достапен е и приказ на RDF тројките.

8.7. SPARQL editor (/queries)

Уредувачот овозможува извршување и модификација на прашалници врз графот на знаење. Корисникот може да избере еден од претходно подготвените прашалници или да внесе сопствен SPARQL код. Резултатите од извршувањето се прикажуваат табеларно и се ажурираат динамички без повторно вчитување на страницата.

8.8. Извештај (/report)

Страницата за извештаи прикажува автоматски генериран аналитички преглед на графот на знаење. Извештајот содржи статистички показатели за бројот на ентитети по класа, информации за недостасувачки ознаки, потенцијални проблеми со кодирањето на текстот и записи кои содржат идентификатори без соодветни називи.

9. Интеграција со интернационални историски бази на податоци

9.1. Wikidata — примарен извор

Wikidata претставува главниот извор на историски податоци. Собирањето се одвива во `scrape.py` преку SPARQL прашалници испратени до <https://query.wikidata.org/sparql>. Процесот започнува од четири seed ентитети:

- **wd:Q221** — Македонија (денешна држава)
- **wd:Q103251** — Македонија (историски регион)
- **wd:Q1145682** — Илинденско востание
- **wd:Q1771831** — Крушевска Република

Оттаму, графот се проширува со ентитети поврзани преку: P1344 (учество во), P793 (значаен настан), P463 (член на), P102 (член на политичка партија), P108 (работодавач), P106 (занимање). За секој собран ентитет, Wikidata URI се зачувува преку `owl:sameAs` врска.

9.2. Надворешни авторитативни бази

Доколку во Wikidata постојат идентификатори за следните надворешни бази, тие се зачувуваат во графот:

Wikidata Prop.	База на податоци	Домен	URI шаблон
P214	VIAF (Virtual International Authority File)	Биографски	https://viaf.org/viaf/{id}
P213	ISNI (Int'l Standard Name Identifier)	Биографски	https://isni.org/isni/{id}
P244	Library of Congress	Библиотечки	https://id.loc.gov/authorities/{id}
P227	GND (Нем. нац. библиотека)	Библиотечки	https://d-nb.info/gnd/{id}
P268	BnF (Фр. нац. библиотека)	Библиотечки	https://catalogue.bnf.fr/ark:/12148/{id}
P269	IdRef (Фр. референтен систем)	Библиотечки	https://www.idref.fr/{id}
P1566	GeoNames	Географски	https://sws.geonames.org/{id}/

Важно е да се напомене дека системот нема директен пристап до овие бази за време на работата на апликацијата, тој само ги зачувува URL во графот и ги прикажува во корисничкиот интерфејс.

9.3. Размена на податоци

Размената на податоци со Wikidata е еднонасочна: системот само чита, не запишува. Брзината на собирање е ограничена со конфигурабилен throttling (минимум 3 секунди меѓу барања) и exponential backoff за Rate Limit одговори. Вкупните лимити конфигурирани во .env датотеката се: PERSON_LIMIT=500, EVENT_LIMIT=350, PLACE_LIMIT=400, ORG_LIMIT=250, DOC_LIMIT=250.

10. Предности и ограничувања на системот

10.1. Предности

- Стандарден RDF/SPARQL модел кој е компатибилен со принципите на семантичкиот веб и може да се интегрира со други Linked Open Data извори.
- Временска димензија реализирана на два нивоа: директни датумски атрибути и OWL-Time именувани интервали.
- Мултилингвални означувања (mk, en, bg, tr, sr, el, sq) за сите ентитети кои тоа го поддржуваат во Wikidata.
- Автоматска валидација и чистење на податоци пред вчитување во базата.
- Автоматски генериран извештај за квалитет на графот.
- Интерактивна визуелизација на три начини: граф, временска линија и карта.
- Конфигурабилни параметри за собирање преку .env датотека (лимити, временски прозорец, throttling).
- SPARQL editor за напредни корисници.

10.2. Ограничувања

- Историскиот опсег е тесен (1885–1910, со личности 1815–1950), дизајниран за демонстративни цели.
- Интеграцијата со надворешните бази е само преку линкови, нема live пребарување или сериализација на нивни записи.
- Scrape.py зависи од достапноста на Wikidata SPARQL endpoint.
- Нема поддршка за уредување или додавање на податоци преку UI.

11. Можни идни подобрувања

- Проширување на историскиот опсег на целата македонска историја (антика, средновековие, Отоманскиот период).
- Додавање на Allen-ова временска алгебра директно во UI за визуелно прашување по временски релации.
- Поддршка за уредување на записи преку UI со SPARQL UPDATE операции.
- Интеграција со националните архиви и дигитализирани документи (State Archives of North Macedonia).
- Имплементација на inference правила (RDFS/OWL reasoning) преку Apache Jena за автоматско изведување нови факти.
- Додавање на full-text пребарување за описи и коментари на ентитетите.
- Export на подграфот во стандардни формати (JSON-LD, Turtle) за корисниците.
- Dockerизирање на целиот стек (FastAPI + Fuseki) за едноставно деплојирање.

12. Заклучок

Овој проект демонстрира практична примена на семантичките веб технологии за структурирање и визуелизација на историско знаење. Системот успешно ги интегрира принципите на Linked Open Data — собирање на RDF тројки од Wikidata, поврзување со меѓународни авторитативни бази и изложување на знаењето преку SPARQL endpoint — со современа веб апликација која нуди интуитивен интерфејс за нетехнички корисници.

Временскиот аспект на графот е реализиран преку два комплементарни механизми: директни датумски атрибути на ентитетите и OWL-Time именувани интервали, кои овозможуваат прецизни темпорални прашувања базирани на Allen-овата алгебра. Интерактивната визуелизација преку D3.js force-directed граф, Leaflet карта и HTMX-базирана временска линија ги прави апстрактните RDF структури разбирливи и истражувачки.

Архитектурата на системот е модуларна и проширлива: скриптите за подготовка на податоци се независни од веб апликацијата, онтолошкиот речник е конзистентен низ целиот систем и SPARQL интерфејсот овозможува напредни корисници да ги прошират вградените прашалници. Проектот претставува солидна основа за понатамошен развој кон поопфатна дигитална историска платформа за македонската историја.